

从 CNN 自适应局地化到低秩状态空间增益修正

—— 一个古气候集合数据同化项目中的机器学习方法迁移记录

读者定位：具备机器学习、数学与数据同化基础，但未曾接触本项目的研究者。**基础文献：**Wang et al. (2023), Convolutional Neural Network-Based Adaptive Localization for an Ensemble Kalman Filter, JAMES. **代码与数据：**online_ml/loc_learning/ (Python + PyTorch 1.12.1, 4×GPU); 缓存于 /data1/wbgu/agentdata/loc_learning/. **制图约定：**所有地图叠加 Natural Earth 110m 海陆线，坐标固定 lon (0,360)、lat (-90,90); 配色按取值域——有正有负 → 蓝-白-红 (RdBu_r)、非负 → 白-红 (Reds)。

摘要

本项目是一个古气候离线集合数据同化 (OSEE) 系统：用三套古气候模拟作为先验，用陆/冰代用资料 (proxy) 作为观测，估计全新世 (约 11 ka BP 以来) 的温度场 (TAS)。系统的基线是类排序集合卡尔曼滤波 (AOEnKF)，在评估窗 (第 601–1100 步，深冰消期盲测) 的 TAS RMSE 为 **0.5021**。

我们以 Wang et al. (2023) 的 CNN 局地化 (CLF/CELF) 为出发点，做了四个阶段的迁移与改造：

阶段	方法	评估窗 TAS RMSE
①	论文式迁移：逐观测 2D U-Net 学习局地化因子 (batch CLF/CELF)	0.5385 – 0.5518 (未超基线)
②	串行一致：以 GC 为残差、可微串行 EnSRF 端到端训练局地化	0.5023 ($\approx$ 基线)
③	低秩状态空间算子：在 AOEnKF 分析增量上学 $\rho = I + UV^\top$	0.4581 – 0.4724 (–6% ~ –8.8%)
④	CELF + PQ 取代 GC 与 inflation：无 GC、无 inflation，逐观测 U-Net + 低秩算子	0.4759 (超 AOEnKF_Opt 0.5021)

核心结论：在本项目中，“学习局地化”几乎无增益空间 (oracle 扫描显示 headroom < 0.3%); 真正的瓶颈是增益/协方差的状态空间结构误差 (跨模式误差)。在完全不改变同化设置的前提下，用一个秩-5 的线性算子修正分析增量，即可获得稳定、可泛化的盲测增益。阶段 ④ 进一步表明：用“学习式 CELF 局地化 + 低秩算子”可以取代 GC 与 inflation 并超越调参最优基线，但其性价比仍略逊于“直接用 GC + 低秩算子”——因为 GC 的价值在于压制高秩远距采样噪声，而低秩算子只能修正低秩结构误差。

1. 项目背景与问题定义

1.1 系统概述

- **状态：**地表气温异常场 TAS，展平为 $n = 6144$ 维 (96 经度 × 64 纬度，经度变化最快)。
- **先验：**三套独立古气候模拟 trace、had_g、had_h，各自提供一条时间序列；按时间步对齐。
- **观测：**约 1276 个陆/冰代用资料站点 (proxy)，每个时刻有部分站点有效，记为 M_t 个观测 ($M_t \approx 380\text{--}720$)。观测值 y 由“伪代理”生成 (真值场在站点处的插值加噪声)，误差方差记为 R_i 。
- **真值 (OSSE)：**一套独立模拟 mpi 的 TAS 场，仅用于评估与 (训练阶段的) 监督，绝不进入同化。
- **时间轴：**共 1100 步 (约 4.5–11 ka BP)。约定：
 - **校准窗** (训练/验证)：第 1–600 步；
 - **评估窗** (盲测)：第 601–1100 步 (深冰消期，模型分歧最大)。

观测网络的空间分布与时间可用性是理解后续所有方法的前提。图 1 给出全部 1276 个代理站点的经纬位置，并以 $t = 850$ 为例标出该时刻有效的 594 个站点；站点在欧洲、北美与北冰洋沿岸高度密集，热带与南半球稀疏。图 2 则对比了真值 mpi 与三套先验的时均异常场，直观显示跨模式差异的量级 (图中共用对称色标 ± 3.2)。图 3 给出每个时刻的有效观测数 M_t ：它从校准窗的约 720 个逐步下降到深冰消期的约 380 个——评估窗的观测更少、问题更难，这一点在后文结果解读中反复出现。




图 1. 代理站点分布。横轴经度 ($0-360^\circ$)，纵轴纬度 ($-90-90^\circ$)。灰色点为全部 1276 个 gwb 代理站点，红色点 (594 个) 为 $t = 850$ 时刻有效、参与同化的站点。解读：站点分布极不均匀（欧亚—北美高纬密集），因此观测的空间代表性在纬度间差异很大；这正是同化中需要 $\cos$ 纬度加权评估、并考虑观测密度的原因。




图 2. 真值与三套先验的时均异常场对比。四个面板分别为 mpi（真值）、trace、had_g、had_h 的 TAS 时均异常场，

共用对称色标 ± 3.2 K（蓝-白-红）。**解读：**三套先验彼此之间、以及它们与真值之间存在明显的**系统性空间差异**，其量级与真值本身的异常幅度相当。这说明本项目的主要误差是**跨模式结构误差**，而不是有限集合的随机采样误差——这是后续方法论选择的根本依据。




图 3. 有效观测数随时间的变化与数据划分。横轴为时间步，纵轴为有效代理数 M_t ；阴影标出 Split A（train 1–550 / val 551–600 / test 601–1100）与 Split B（train 601–1100 / test 1–550）的划分。**解读：** M_t 在评估窗明显偏低（约 380–720），意味着盲测是在观测更稀疏、气候信号更强的时段完成的；任何在评估窗取得的改进都发生在更不利的条件下。

1.2 记号约定

符号	含义	维度
n	TAS 状态维数	6144
K	集成员数	100
$M = M_t$	t 时刻有效观测数	约 380–720
η	膨胀系数 (inflation)	1.5
$\mathbf{x}_f$	先验集合均值	n
$\mathbf{x}_t$	真值场	n
$\mathbf{d}$	新息 $y - H\mathbf{x}_f$	M
K_s	样本（全矩阵）卡尔曼增益	$n \times M$
ρ_{GC}	Gaspari–Cohn 局地化权重（截断半径 7500 km）	$M \times n$
w_j	评估权重 $\cos(\text{lat}_j)$	n

1.3 核心问题

传统集合 DA 中，**有限集合**会产生远距离伪相关，需要**局地化**抑制。本项目的基线 AOEnKF 采用 Gaspari–Cohn (GC) 局地化。我们的出发点正是论文的“用 CNN 学习自适应局地化”。但在推进中我们发现：

1. **局地化不是本项目的瓶颈**——最优 GC 与任何局地化变体之间的差距 $< 0.3\%$ (§ 6.4 给出 oracle 扫描证据)；
2. **真正的误差来源是跨模式结构误差**（见图 2）；
3. 因此需要一个**能修正增益/协方差状态空间结构**的算子，而不是逐点压制相关。

2. 数据同化预备

本节为后文提供最小必要的 DA 背景（熟悉 EnKF 的读者可跳过）。

2.1 集合卡尔曼滤波（EnKF）与样本增益

设先验集合 $\{x^{(k)}\}_{k=1}^K$ ，集合均值 $\bar{x}$ ，偏差 $X' = [x^{(1)} - \bar{x}, \dots]$ 。线性观测算子 H （本项目中为双线性插值到站点），观测误差协方差 R 。样本增益为

$$K_s = PH^\top (HPH^\top + R)^{-1}, \quad P = \frac{1}{K-1} X' X'^\top.$$

分析均值为

$$\mathbf{x}_a = \mathbf{x}_f + K_s \mathbf{d}, \quad \mathbf{d} = y - H\mathbf{x}_f.$$

2.2 局地化

有限集合使 P 含远距离伪相关。局地化通过逐元素乘积抑制：

$$\mathbf{x}_a = \mathbf{x}_f + (\rho \circ K_s) \mathbf{d},$$

其中 ρ 为局地化矩阵。经典的 Gaspari-Cohn (GC) 函数仅依赖距离 r ：

$$\rho_{\text{GC}}(r) = \begin{cases} 1 - \frac{5}{3}s^2 + \frac{5}{8}s^3 + \frac{1}{2}s^4 - \frac{1}{4}s^5, & 0 \leq s \leq 1, \\ \frac{2}{3}s^{-1}(8s^2 + 4s - 1 - \frac{1}{2}s^3) + \frac{1}{2}s^{-1}\ln s, & 1 < s \leq 2, \\ 0, & s > 2, \end{cases} \quad s = \frac{r}{c},$$

本项目取 $c = 7500$ km。

2.3 串行 EnSRF (operational 更新)

本项目的 operational 更新是逐观测串行 EnSRF (增广状态 $A = [X; H]$, 后 M 行为成员在站点处的值)：

$$\begin{aligned} h_i &= A'_{n+i}, & \nu_i &= \frac{1}{K-1} h_i h_i^\top + R_i, \\ \text{PHT}_i &= \frac{1}{K-1} A' h_i^\top, & f_i &= \frac{1}{1 + \sqrt{R_i/\nu_i}}, \\ c_i &= [\rho_i; \rho_{pp,i}^{\text{GC}}], & kg_i &= c_i \circ \text{PHT}_i / \nu_i, \\ \bar{A} &\leftarrow \bar{A} + kg_i (y_i - \bar{A}_{n+i}), & A' &\leftarrow A' - f_i kg_i h_i. \end{aligned}$$

循环结束得到 AOEnKF 分析均值 $\mathbf{x}_a^{\text{serial}} = \bar{A}_{1:n}$ 。

2.4 评估度量

评估采用 $\cos$ 纬度加权的 RMSE：

$$\text{RMSE} = \sqrt{\frac{\sum_j w_j (e_j)^2}{\sum_j w_j}}, \quad w_j = \cos(\text{lat}_j).$$

基线 (canonical AOEnKF, $K = 100$ 、GC 7500 km、inflation 1.5)：全窗 0.3658 / 评估窗 0.5021。

3. 论文方法回顾 (Wang et al., 2023)

论文用 CNN 学习局地化函数，两种监督方式：

- **CLF (CNN Localization Function)**: 输入样本增益矩阵 K ，输出局地化后的增益 $L(K)$ ，与“大集合真增益” K_{true} 配对：

$$\mathcal{L}_{\text{CLF}} = \|L(K) - K_{\text{true}}\|_F^2.$$

- **CELF (CNN Ensemble Localization Function)**: 同架构，但损失为后验误差（需真值 $\mathbf{x}_t$ ）：

$$\mathcal{L}_{\text{CELF}} = \frac{\sum_j w_j (x_{a,j} - x_{t,j})^2}{\sum_j w_j}, \quad \mathbf{x}_a = \mathbf{x}_b + L(K)(y - H\mathbf{x}_b).$$

- **论文网络**: 3 层 Conv2D ($64@27 \times 27 \rightarrow 32@15 \times 15 \rightarrow 1@9 \times 9$) + ReLU + 线性输出，作用于 $\text{state} \times \text{obs}$ 的规则 2D 增益矩阵。
- **经验**: 局地化依赖位移（非对称）；自适应权重可 > 1 ；patch 分解可提效；训练（offline）与循环同化之间存在 domain shift。

迁移到本项目的两个结构性差异：

1. 本项目观测是不规则站点，无法把 $\text{state} \times \text{obs}$ 当成规则 2D 图 $\rightarrow$ 改为逐观测列的“状态 2D 图” (64×96) 去噪；
2. 本项目是跨模式误差主导，而非论文的采样误差 $\rightarrow$ CLF 的“大集合真增益”目标会被模式误差污染，CELF（对真值）更合适。

4. 阶段 ①：论文式迁移 (batch CLF / CELF)

4.1 数据构造 (build_pairs.py::main())

对训练窗 $t = 1..600$ ，每个时刻：

```
观测:      idx, y, R   = o.select_obs(t, ...)
候选池:    srch       = o.search_range(t, tm)           # |pool_time - t| ≤ 250
类比选择:  idx       = o.select_analog(y, idx, srch, hx, plat) # K=100
E = tas[:, idx]       (6144 × K)
Hc = hx[idx, obs_idx] (K × M)
膨胀:      Ed = η · (E - Ê),   Hd = η · (Hc - Hc)       # η = 1.5
```

样本全增益（与 operational 先验一致）：

$$C_{hh} = \frac{H_d^\top H_d}{K - 1}, \quad C_{xh} = \frac{E_d H_d}{K - 1}, \quad K_s = C_{xh} (C_{hh} + \text{diag}(R))^{-1} \in \mathbb{R}^{n \times M}.$$

大集合目标（CLF 的“真增益”）：用全部候选（约 1500 个，不膨胀）

$$K_l = C_{xh}^l (C_{hh}^l + \text{diag}(R))^{-1}.$$

另存先验均值 $\mathbf{x}_f$ 、真值 $\mathbf{x}_t$ 、先验离散度 spread、新息 $\mathbf{d}$ ，存为 pairs/t####.npz。

4.2 神经网络架构详解 (train_loc.py::UNet)

由于观测不规则，我们采用逐观测列的 2D 去噪器：对每个观测 j ，把整张 TAS 网格当作图像输入，输出同尺寸的局地化因子场。整体流程如图 4 所示：先验集合经 AOEnKF 产生分析增量，学习模块只在增量上作用。




图 4. 方法流程示意。先验集合 ($K = 100$, 由 $t \pm 250$ 窗内的类比成员构成) 与观测进入串行 AOEnKF (GC 7500 km, inflation 1.5), 得到分析场 $\mathbf{x}_a^{\text{serial}}$; 取其与集合均值的差作为增量 $\mathbf{z}_3$; 学习到的低秩状态算子 $\rho = I + UV^\top$ 作用于 $\mathbf{z}_3$, 得到最终分析场。**解读**: 学习组件与同化循环解耦——这正是阶段 ③ 能稳定泛化的关键设计。

(a) 基本模块 ConvBlock

$$\text{ConvBlock}(c_{\text{in}}, c_{\text{out}}) = \text{Conv}_{3 \times 3}(c_{\text{in}}, c_{\text{out}}) \rightarrow \text{LeakyReLU}(0.1) \rightarrow \text{Conv}_{3 \times 3}(c_{\text{out}}, c_{\text{out}}) \rightarrow \text{LeakyReLU}(0.1).$$

(b) U-Net 结构 (输入 $4 \times 64 \times 96$)

阶段	操作	输出尺寸	参数量
输入	4 通道	$4 \times 64 \times 96$	—
e1	ConvBlock(4,32)	$32 \times 64 \times 96$	10,432
↓ pool	MaxPool 2×2	$32 \times 32 \times 48$	—
e2	ConvBlock(32,64)	$64 \times 32 \times 48$	55,424
↓ pool	MaxPool 2×2	$64 \times 16 \times 24$	—
e3	ConvBlock(64,64)	$64 \times 16 \times 24$	73,856
↓ pool	MaxPool 2×2	$64 \times 8 \times 12$	—
bottleneck	ConvBlock(64,128)	$128 \times 8 \times 12$	221,440
↑ u3	上采样 + 拼接 e3 → ConvBlock(192,64)	$64 \times 16 \times 24$	147,584
↑ u2	上采样 + 拼接 e2 → ConvBlock(128,64)	$64 \times 32 \times 48$	110,720
↑ u1	上采样 + 拼接 e1 → ConvBlock(96,32)	$32 \times 64 \times 96$	36,928
out	Conv $_{1 \times 1}$ (32, 1)	$1 \times 64 \times 96$	33
合计			656,417

输出层零初始化, 并写成

$$\rho = 1.0 + \text{out}(y_1),$$

即训练起点为 $\rho \equiv 1$ (“无局地化”), 网络只需学习一个残差。

(c) 感受野与复杂度: 标称感受野约 167 像素 (在 64×96 网格上相当于全局); 单张图像前向约 0.65 GMAC。

(d) 输入张量规格: 对观测 j , 输入为 $4 \times 64 \times 96$, 四个通道分别为

通道	内容	归一化
0	样本增益列 $K_s[:, j]$	除以全局尺度 k_s
1	观测 j 到各格点的球面距离	除以 8000 km
2	$\cos(\text{lat})$	—
3	先验集合离散度 spread	除以全局尺度

签名: `make_input(ks_col, dist_col, coslat, spread, ks_scale, spread_scale) -> (4, 64, 96)`; 批量前向时输入为 $(B, 4, 64, 96)$ 。

(e) 输出规格: $(B, 1, 64, 96)$, 即每个观测对应一张局地化因子图 $\rho_j \in \mathbb{R}^{64 \times 96}$, 展平后 $\rho \in \mathbb{R}^{M \times n}$ 。

4.3 训练 (train_loc.py::main())

CLF (每步随机抽 8 列):

$$\mathcal{L}_{\text{CLF}} = \frac{1}{|\Omega|} \sum_{j \in \Omega} \left\| \rho_j \odot \frac{K_s[:,j]}{k_s} - \frac{K_l[:,j]}{k_s} \right\|_W^2.$$

CELF (全部 M 列):

$$\text{contrib} = \sum_{j=1}^M K_s[:,j] \odot (\rho_j \text{innov}_j), \quad \mathbf{x}_a = \mathbf{x}_f + \text{contrib}, \quad \mathcal{L}_{\text{CELF}} = \|\mathbf{x}_a - \mathbf{x}_t\|_W^2.$$

优化: Adam, lr = 10^{-4} , 30 epoch, 训练 1–550 / 验证 551–600, ReduceLRonPlateau, 按验证损失保存 loc_clf.pt / loc_celf.pt。

4.4 输出如何作用于同化

- **batch (论文式)**: $\mathbf{x}_a = \mathbf{x}_f + (K_s \circ \rho^\top) \mathbf{d}$ 。
- **串行 (operational)**: 把串行 EnSRF 局地化向量 c_i 的**状态部分**替换为网络输出 ρ_i , obs-obs 块保持 GC:

$$xb = \begin{bmatrix} E \\ H_c^\top \end{bmatrix}, \quad c_{\text{mat}} = [\rho \mid \rho_{\text{GC},pp}[\text{idx}, \text{idx}]], \quad \mathbf{x}_a = \text{serial_ensrf}(xb, y, R, c_{\text{mat}}).$$

4.5 结果与失败诊断

图 5 给出评估窗内各变体的逐时 RMSE 曲线。




图 5. 阶段 ① 在评估窗的逐时 RMSE 对比。横轴为时间步 601–1100，纵轴为 TAS RMSE。黑线为 canonical 串行 AOEnKF (均值 0.5021)；橙线为 batch GC (0.5403)；红线为 batch CELF (0.5385)；绿线为串行 CELF (clip[0,1.2], 0.5355)。**解读：**三种学习/局地化变体的逐时曲线几乎全程高于黑线（基线），说明在本项目上“学习局地化”并未带来改善；绿线（串行 CELF）后期略接近基线，但仍未超越。逐时曲线的强噪声也表明单步比较意义有限，需看均值。

变体	全窗	评估窗
prior (不更新)	0.4617	0.6568
unloc (无局地化)	0.4231	0.5883
GC (batch)	0.3854	0.5403
CLF (batch)	0.3866	0.5518
CELF (batch)	0.3725	0.5385
canonical 串行 AOEnKF	0.3658	0.5021
串行 CLF (clip[0,1.2])	—	0.5204
串行 CELF (clip[0,1.2])	—	0.5355

诊断: - CELF 在匹配的 batch 框架下全窗 0.3725 优于 batch GC 0.3854, 但评估窗几乎持平; - CLF 相对大集合增益的 Frobenius 误差更小 (0.685 vs GC 0.752), 却不转化为 RMSE; - 串行部署发散 (无 clamp), 说明 batch 训练与串行 EnSRF 存在域不匹配; - 根因: 局地化 headroom $< 0.3\%$ (§ 6.4), 且 batch/serial 更新机制不同。

5. 阶段 ②: 串行一致 GC 残差局地化

动机: 让训练目标与 operational 串行 EnSRF 完全一致, 并把局地化写成 GC 的有界残差。

5.1 可微串行 EnSRF (`serial_torch.py::serial_analysis`)

将 § 2.3 的串行循环用 PyTorch 实现, 使局地化向量 c_i 可微。对第 i 个观测:

$$h_i = A'_{n+i}, \quad \nu_i = \frac{h_i h_i^\top}{K-1} + R_i, \quad \text{PHT}_i = \frac{A' h_i}{K-1}, \quad kg_i = \frac{c_i \circ \text{PHT}_i}{\nu_i},$$

$$\bar{A} \leftarrow \bar{A} + kg_i(y_i - \bar{A}_{n+i}), \quad A' \leftarrow A' - f_i kg_i h_i, \quad f_i = \frac{1}{1 + \sqrt{R_i/\nu_i}}.$$

已验证该实现与 numpy/MATLAB 的 canonical AOEnKF 逐位一致 (差异 $\sim 10^{-16}$)。

5.2 网络架构: 位移特征 MLP (`train_serial.py::MLP`)

局地化因子被参数化为 GC 的乘性有界残差:

$$\rho_{ij} = \text{clip}\left(\rho_{\text{GC},ij} \cdot \exp(\tanh g_\theta(\varphi_{ij})), 0, 2\right),$$

其中特征向量 (7 维)

$$\varphi_{ij} = \left[\frac{d_{ij}}{7500}, \cos \Delta \lambda_{ij}, \sin \Delta \lambda_{ij}, \Delta \phi_{ij}, \cos(\text{lat}_j), \frac{\sigma_j}{\sigma}, \log\left(1 + \frac{|K_{s,ij}|}{K_s}\right) \right].$$

网络为 $7 \rightarrow 64 \rightarrow 64 \rightarrow 1$ 的 MLP (Tanh 激活), 末层零初始化, 故训练起点 $\rho = \rho_{\text{GC}}$ 。参数量 4,737。

输入/输出: 输入 ($N_{\text{pairs}}, 7$) (N_{pairs} 为 GC 支撑域内的 (观测, 格点) 对数); 输出 ($N_{\text{pairs}}, 1$), 即 $\delta = \tanh g_\theta$ 。

5.3 训练与结果

损失:

$$\mathcal{L} = \mathcal{L}_{\text{CELF}} + 0.1 \mathcal{L}_{\text{CLF}} + 10^{-3} \overline{\delta^2}.$$

结果：全窗 0.3657、评估窗 0.5023 ($\approx$ 基线)。训练后 $\exp(\delta) \approx 1.08$ 近似均匀，即网络退化为 $1.08 \times \text{GC}$ ——局地化没有可学空间。

6. 阶段③：低秩状态空间算子（成功）

动机：既然局地化（逐元素压制）不是瓶颈，就改为修正增益的状态空间结构。做法是完全不动同化设置，只在 AOEnKF 输出的分析增量上学一个低秩线性算子（流程见图 4）。

6.1 公式

$$\mathbf{z}_3 = \mathbf{x}_a^{\text{serial}} - \mathbf{x}_f \quad (\text{AOEnKF 分析增量}),$$

$$\rho = I + UV^\top, \quad U, V \in \mathbb{R}^{n \times r}, \quad \mathbf{x}_a = \mathbf{x}_f + \rho \mathbf{z}_3 = \mathbf{x}_f + \mathbf{z}_3 + U(V^\top \mathbf{z}_3).$$

- $V^\top \mathbf{z}_3 \in \mathbb{R}^r$ ：把增量投影到 r 个方向；
- $U(\cdot)$ ：把 r 个系数线性组合回全状态并相加；
- 等价于有效增益 $K_{\text{GC}} \rightarrow (I + UV^\top)K_{\text{GC}}$ 的秩- r 修正。

6.2 训练 (train_matrix_rho.py / validate_t0.py)

预计算 $\mathbf{z}_3$ (build_serial_analysis.py)，损失：

$$\mathcal{L}(U, V) = \frac{\sum_t w^\top (\mathbf{x}_a(t) - \mathbf{x}_t(t))^2}{\sum w} + \lambda(\|U\|_F^2 + \|V\|_F^2).$$

签名：train_matrix_rho.py::main() (参数 --base {b1,b2,b3}、--r、--lr、--lam、--noclf、--diag、--tag)；validate_t0.py::train(Z,XF,XT,w,tr,va,r,lam,seed,epochs=5000)；rmse_t(xa,xt,w)。

划分：Split A (训练 1–550 / 验证 551–600 / 测试 601–1100) 与 Split B (训练 601–1100 / 测试 1–550)。关键实现细节： U, V 必须随机小初始化（零初始化是鞍点，梯度恒为 0）。

图 6 给出两类秩 ($r = 5, 20$) 在两个划分上的训练/验证损失曲线。




图 6. 阶段③ 的训练与验证损失曲线。左/右面板分别为 Split A/B；实线为训练 CELF，虚线为验证 CELF；红 = $r = 5$ ，蓝 = $r = 20$ ；纵轴为对数尺度。解读：训练损失持续下降而验证损失很快进入平台，说明模型在少量 epoch 后即达到最优，之后主要是过拟合；因此结果依赖早停（验证损失最低点）。这也解释了为何更大秩 ($r = 20$) 在训练集上更低，但最终测试表现需由评估窗判定。

6.3 结果

图 7 与图 8 给出主结果：评估窗逐时 RMSE 与三口径汇总。




图 7. 评估窗逐时 RMSE (含分箱改善)。上排两个面板分别为 Split A (test 601-1100) 与 Split B (test 1-550) 的逐时 TAS RMSE：细线为逐步值，粗线为 25 步滑动平均；黑 = AOEnKF，红 = + r_5 ，蓝 = + r_{20} 。下排为每 50 步分箱的平均改善量 (AOEnKF - 算子，正值表示更好)。解读：算子 (红/蓝) 在绝大多数时间步上低于基线 (黑)，改善在 750-950 步最明显；分箱图显示改善不是全程均匀的，在约 600-650 与 950-1050 段较弱甚至接近零。这说明增益是时间局部的，而非均匀平移。




图 8. 三口径汇总对比。横轴为三组口径：Split A 测试（601-1100）、Split B 测试（1-550）、无泄漏全窗（A、B 的测试段并集）；每组三根柱为 AOEnKF、 $+r5$ 、 $+r20$ ，柱顶标注相对基线的改善百分比。**解读：**所有口径下算子都优于基线；评估窗从 0.5021 降到 0.4724 ($r5$) / 0.4581 ($r20$)，改善 5.9%/8.8%；早期段（B）改善较小（2.7%/4.2%），因为基线本身已较好（0.2510）。这体现了“**基线越弱、修正收益越大**”的规律。




图 9. Taylor 图（评估窗）。角向为与真值的相关系数，径向为标准差比，青色点线为 RMSD 等值线；灰 = 先验，黑 = AOEnKF，红 = $+r5$ ，蓝 = $+r20$ 。**解读：**算子同时提高了相关（0.84→0.86）与标准差比（0.79→0.82/0.89），即**更准且振幅更接近真值**。所有点的标准差比都小于 1，说明先验/分析整体偏弱（欠离散），算子的振幅放大正是其作用之一。




图 10. 纬向平均绝对误差。横轴为绝对误差（对经度与时间平均），纵轴为纬度；黑 = AOEnKF，红 = +r5，蓝 = +r20。**解读：**改善主要集中在北半球中高纬（误差最大的区域），但在约 60°N 与 40°S 附近存在补偿带——少数纬度上算子反而略差。这再次说明改进是空间局部的，需结合空间图（图 11）理解。




图 11. 时间平均误差的空间分布。左：AOEnKF 的时间平均 $|e|$ ；中：+r5 的对应量；右：两者之差（蓝-白-红，红 = 改善）。三幅共用色标 $[0, 3.70]$ 。**解读：**误差热点位于北大西洋—北极（约 lon 300°/lat 55–60°）与欧亚大陆（lon 0–30°/lat 10°），算子在热点处明显降误差；差值图同时显示若干蓝色（变差）小区域。**因此全局 RMSE 的 -6% 是由局地热点贡献的，并非全域均匀改善。**

6.4 稳健性与机制

(a) 随机种子与超参数。图 12 给出 5 个随机初始化的测试 RMSE 分布，图 13 给出 $r \times \lambda$ 网络的敏感性。

Seed robustness ($r=5$, $\lambda=1e-3$); box collapses because $\text{std} \leq 1e-4$




图 12. 随机种子稳健性。左/右为 Split A/B；每个箱体为 5 个随机种子下的测试 RMSE，虚线为对应基线。解读：箱体极窄 ($\text{std} \leq 10^{-4}$)，说明结果对初始化几乎不敏感——因为目标是凸的线性最小二乘型问题，优化稳定。

Parameter sensitivity (test RMSE); white = better, red = worse




图 13. 参数敏感性 ($r \times \lambda$)。两面板为 Split A/B，颜色为测试 RMSE（白 = 更好、红 = 更差），格内标数值。解读： r 增大改善 ($r = 20$ 最好)，正则 $\lambda > 0$ 略劣于 $\lambda = 0$ ；整体趋势平稳，不存在需要精细调参的“悬崖”。

(b) **oracle 局地化扫描**。为界定“学习局地化”的上限，我们对 GC 半径 (5000–15000 km) 与幅值 (0.7–1.6) 做了网格扫描：验证窗最好仅 +0.28%，评估窗最好仅 +0.16%。这从经验上证明局地化 headroom $< 0.3\%$ ，因此阶段 ①② 的“无增益”是结构性的，而非训练不充分。

(c) **反向验证**。图 14 给出 Split B (训练晚段、测试早段) 的空间误差图，验证改进不是“只在深冰消期偶然成立”。




图 14. Split B 的空间误差 (反向验证)。左/中/右同图 11，但为 Split B 测试段 (1–550)，共用色标 $[0, 1.85]$ 。解读：即使时间方向相反 (用晚期训练、早期测试)，算子仍在误差热点处降低误差，说明学到的修正具有跨时段的可

迁移性。

(d) 修正的几何本质。图 15 用消融说明增益来自“非对角混合”而非“缩放”；图 16–18 进一步刻画算子的谱结构与作用方式。




图 15. 标量缩放 vs 逐格点对角缩放 vs 低秩算子。横轴为方法，纵轴为测试 RMSE，两面板为 Split A/B。解读：全局标量缩放（A 0.5030、B 0.2514）与逐格点对角缩放（A 0.5214、B 0.2613）都差于或等于基线；只有含非对角项的低秩算子显著更好（A 0.4724、B 0.2442）。这直接证明增益来自跨格点的状态混合，而不是任何形式的逐点缩放。




图 16. 学习算子的奇异谱。横轴为奇异值序号，纵轴为 U 的奇异值；红 = $r5$ ，蓝 = $r20$ 。解读：谱快速衰减（ $r5$ 的首个奇异值 1.20，第五个 0.18），说明有效自由度很低——少数几个方向主导了修正，这解释了为何 $r = 5$ 已能取得大部分增益。




图 17. 修正场快照 ($t = 723$, 改善较大的时刻)。左上: AOEnKF 增量 $\mathbf{z}_3$ (蓝-白-红); 右上: 学到的修正 $U(V^\top \mathbf{z}_3)$; 左下: AOEnKF 的 $|e|$; 右下: $+r_5$ 的 $|e|$ (下方两幅共用色标 $[0, 2.68]$)。解读: 增量在 $\text{lon} \approx 120^\circ / \text{lat} \approx 45^\circ$ 有强正值; 修正场虽整体幅度小, 但在关键区域有结构; 对应地, 右下误差在 $\text{lon} \approx 300^\circ / \text{lat} \approx 55^\circ$ 处较左下明显减小。这直观展示了“在增量上做小幅结构化修正即可降低分析误差”。




图 18. 修正能量比随时间的变化。纵轴为 $\|U(V^\top \mathbf{z}_3)\| / \|\mathbf{z}_3\|$, 横轴为时间步, 阴影标出划分。解读: 训练窗内比值约 0.7–0.9, 评估窗内约 0.2–0.5。评估窗修正能量更低, 说明算子在外推时段自动采取更保守的修正——这与其仍能改善 RMSE 的事实共同表明: 修正不需要很大幅度, 关键是方向正确。




图 19. 改善/变差的空间与时间分解 (Split A)。左：每个格点上“算子优于基线”的时间占比（0-1，白-红）；右：每 50 步分箱的平均改善量，标题给出全局统计——改善占 55.9%，变差占 44.1%。解读：改善与变差大致是“局部多数改善”的格局；这既解释了净增益（-6%），也如实揭示了方法并非普适——读者不应期待全域、全时段的单调改进。

6.5 结果汇总

口径	AOEnKF	+r5 ($\lambda = 10^{-3}$)	+r20 ($\lambda = 0$)
Split A 测试 601-1100	0.5021	0.4724 $\pm$ 0.0001	0.4581
Split B 测试 1-550	0.2510	0.2442	0.2404
无泄漏全窗	0.3706	0.3529	0.3441

实测 $A = UV^\top$ ($r = 5$):

$$\|A\|_F = 1.577, \quad \|\text{diag}(A)\|_F = 0.0475, \quad \|\text{offdiag}(A)\|_F = 1.576,$$

非对角能量占比 99.91%；测试窗修正量中对角部分占比 1.8×10^{-5} 。也就是说， ρ 不是对角矩阵，增益几乎全部来自跨格点的非对角混合（与图 15 一致）。

7. 三阶段对比与结论

	① batch CLF/CELF	② 串行 GC 残差	③ 低秩状态算子
学习对象	局地化因子 ρ （逐观测 2D 图）	局地化因子 ρ （位移特征）	状态空间算子 $\rho = I + UV^\top$
作用位置	batch 更新	串行循环内 c_i	循环后作用于 $\mathbf{z}_3$
训练目标	CLF / CELF	CELF + 0.1 CLF	CELF
是否改同化设置	是（局地化）	是（局地化）	否
评估窗 RMSE	0.5385 – 0.5518	0.5023	0.4581 – 0.4724
结论	无效（headroom / 域差）	无效（ $\approx$ 基线）	有效（-6% ~ -8.8%）

结论：1. 论文式“学习局地化”在本项目无空间（oracle headroom $< 0.3\%$ ，图 13 后的讨论），且 batch 训练与串行部署存在域差（图 5）；2. 真正的瓶颈是增益/协方差的状态空间结构（跨模式误差）（图 2、图 15）；3. 用低秩状态空间算子修正 AOEnKF 分析增量，可在完全保留同化设置的前提下取得真实、可泛化的盲测增益（图 7-图 19）。

8. 复现指南

环境: conda paleo_da_ml (Python 3 + torch 1.12.1 + cu121, 4 GPU)。

数据准备

```
python build_pairs.py          # 阶段①配对增益 -> /data1/.../loc_learning/pairs/
python build_matrix_cache.py    # 阶段③ batch 缓存
python build_serial_analysis.py # 阶段③ 串行增量 z3
```

训练

```
python train_loc.py --loss clf # 阶段① CLF
python train_loc.py --loss celf # 阶段① CELF
python train_serial.py --r 3    # 阶段②
python train_matrix_rho.py --base b3 --r 5 --lam 1e-3 --noclf --tag mrho_b3_r5
```

评估

```
python eval_batch.py          # 阶段① batch
python eval_serial.py --ckpt results/loc_celf.pt --tag celf_clip --lo 0 --hi 1.2
python validate_t0.py         # 阶段③ T0 可靠性验证
```

图件

```
python fig_precompute.py && python fig_make.py
```

9. 符号表

符号	含义
$n = 6144$	TAS 状态维数 ($96 \text{ lon} \times 64 \text{ lat}$)
$K = 100$	类比集合成员数
$M = M_t$	有效观测数 (约 380–720)
$\eta = 1.5$	inflation
ρ_{GC}	Gaspari–Cohn 局地化 (7500 km)
E, H_c	集合状态 ($n \times K$) / 观测块 ($K \times M$)
K_s	样本全增益 ($n \times M$)
K_l	大集合增益 ($n \times M$), CLF 目标
$\mathbf{x}_f, \mathbf{x}_t$	先验均值、真值
$\mathbf{d}$	新息 $y - H\mathbf{x}_f$
$\mathbf{z}_3$	AOEnKF 分析增量 $\mathbf{x}_a^{\text{serial}} - \mathbf{x}_f$
ρ, U, V, r	低秩状态算子、低秩因子、秩
w_j	$\cos(\text{lat}_j)$

10. 附录

10.1 网络参数量

- 阶段 ① U-Net: **656,417** (逐模块见 § 4.2 表)。
- 阶段 ② MLP: $7 \cdot 64 + 64 + 64 \cdot 64 + 64 + 64 + 1 = \mathbf{4,737}$ 。
- 阶段 ③: 无神经网络, 仅 $U, V \in \mathbb{R}^{6144 \times r}$, $r = 5$ 时约 6.1×10^4 个可训练参数。

10.2 主要超参数

阶段	超参数
①	集合 $K = 100$; 窗 ± 250 ; $\eta = 1.5$; $\text{lr } 10^{-4}$; epoch 30; 训练 1-550 / 验证 551-600; CLF 每步 8 列
②	MLP $7 \rightarrow 64 \rightarrow 64 \rightarrow 1$; $\rho_{\max} = 2$; CELF+0.1CLF+ 10^{-3} 正则
③	$r \in \{5, 20\}$; $\lambda \in \{0, 10^{-3}, 10^{-2}\}$; 全批量 Adam; 5000 epoch; 训练 1-550 / 验证 551-600

10.3 复杂度

- 阶段 ① 单张 64×96 图像前向约 0.65 GMAC; 每个时刻需对 M_t 个观测分别前向。
- 阶段 ③ 修正量 $U(V^\top \mathbf{z}_3)$ 仅 $O(nr)$, 可忽略不计。

图目录

图	文件	位置
图 1	figs/F15_proxies.png	§ 1.1
图 2	figs/F16_truth_prior.png	§ 1.1
图 3	figs/F9_Mt_splits.png	§ 1.1
图 4	figs/F17_flow.png	§ 4.2
图 5	loc_learning_comparison.png	§ 4.5
图 6	figs/F8_training_curves.png	§ 6.2
图 7	figs/F1_rmse_timeseries.png	§ 6.3
图 8	figs/F2_summary_bars.png	§ 6.3
图 9	figs/F4_taylor.png	§ 6.3
图 10	figs/F5_zonal_error.png	§ 6.3
图 11	figs/F3_error_maps.png	§ 6.3
图 12	figs/F6_seed_box.png	§ 6.4
图 13	figs/F7_param_heatmap.png	§ 6.4
图 14	figs/F19_error_maps_B.png	§ 6.4
图 15	figs/F11_scalar_diag_lowrank.png	§ 6.4
图 16	figs/F12_singular_spectra.png	§ 6.4
图 17	figs/F13_snapshot.png	§ 6.4
图 18	figs/F14_energy_ratio.png	§ 6.4
图 19	figs/F18_improve_degrade.png	§ 6.4
图 20	figs/F26_new_scheme_celf_pq.png	§ 11.4
图 21	figs/F27_celf_error_spectrum.png	§ 11.5
图 22	figs/F28_new_scheme_timeseries.png	§ 11.5

注: F10 (真值模型鲁棒性 T0-T3) 为 Phase 2 待补, 故未编号。

附: 代码与产物索引

代码(online_ml/loc_learning/) - 数据/引擎: osee_tas.py, serial_torch.py, build_pairs.py, build_matrix_cache.py, build_serial_analysis.py - 阶段 ①: train_loc.py (UNet/CLF/CELF)、eval_batch.py, eval_serial.py - 阶段 ②: train_serial.py - 阶段 ③: train_matrix_rho.py, validate_t0.py, finalize_t0.py - 阶段 ④: build_raw_pairs.py, build_raw_cache.py, train_celf_raw.py, eval_celf_raw.py, train_pq_on_zC.py, verify_zC_pq.py, make_fig_zC.py, make_fig_zC2.py - 图件: fig_precompute.py, fig_make.py, coastline.py

数据缓存 (/data1/wbgu/agentdata/loc_learning/) - pairs/, serial/, matrix_cache.npz, matrix_cache_serial.npz - 阶段 ④: pairs_raw/, raw_ensemble_cache.npz (raw batch/serial 结果)、matrix_cache_serial_zC.npz

11. 阶段 ④: CELF + PQ 取代 GC 与 inflation (无 GC、无 inflation)

11.1 动机

阶段 ③ 的成功建立在 canonical AOEnKF (含 GC 局地化 + inflation) 之上: 它在已处理好的分析增量 $\mathbf{z}_3$ 上叠加低秩算子。一个自然的问题是:

能否彻底去掉 GC 与 inflation, 让学习算子自己承担这两件事, 并且仍然优于调参最优的 AOEnKF_Opt (0.5021)?

我们此前的实验 (REPORT6.md) 已经回答了一半: 单纯的低秩算子 $\rho = I + UV^\top$ 无法取代 GC。把 GC ($\mathbf{c}_i = \mathbf{1}$) 与 inflation ($\eta = 1$) 去掉后, raw ensemble 的评估窗 RMSE 为 0.5805, 即使加低秩算子 (r 到 50) 也只能到 0.5406, 仍显著劣于 AOEnKF_Opt 0.5021。原因是结构性的:

- GC 是“高秩、随距离、随观测”的算子, 负责压制有限集合 ($K = 100$) 产生的远距伪相关;
- PQ 是“低秩、全局、无距离概念”的算子, 无法表达这种空间非均匀的高秩压制。

因此本阶段引入 CELF 网络 (逐观测、可表达空间非均匀与方向性, 且可 > 1 兼任 inflation) 来承担 GC 的角色, 再叠加 PQ 做低秩结构修正。

11.2 公式

基础 (raw ensemble, 无 inflation): 设先验集合 $X \in \mathbb{R}^{n \times K}$ 、观测块 $H \in \mathbb{R}^{M \times K}$,

$$\begin{aligned} E_d &= X - \bar{X}, \quad H_d = H - \bar{H}, \\ C_{xh} &= \frac{1}{K-1} E_d H_d^\top, \quad C_{hh} = \frac{1}{K-1} H_d^\top H_d, \\ K_0 &= C_{xh} (C_{hh} + \text{diag}(R))^{-1} \in \mathbb{R}^{n \times M}, \quad \mathbf{d} = \mathbf{y} - \bar{H}. \end{aligned}$$

阶段 A1 (CELF, 替代 GC + inflation):

$$\rho_{ij} = \text{clip}(1 + g_\theta(\varphi_{ij}), 0, 1.5), \quad \mathbf{x}_a^C = \mathbf{x}_f + \sum_{j=1}^M (\rho_{\cdot j} \odot K_{0, \cdot j}) d_j, \quad \mathbf{z}_C = \mathbf{x}_a^C - \mathbf{x}_f.$$

其中 g_θ 为逐观测 2D U-Net (§ 11.3), g_θ 初值为 0 使 $\rho \equiv 1$ (即无局地化、无膨胀的起点)。

阶段 A2 (PQ, 低秩状态算子):

$$\mathbf{x}_a = \mathbf{x}_f + \mathbf{z}_C + U (V^\top \mathbf{z}_C), \quad U, V \in \mathbb{R}^{n \times r}, \quad \rho_{PQ} = I + UV^\top.$$

损失 (两阶段均为 CELF, 加权后验误差):

$$\mathcal{L}(U, V) = \frac{1}{|\text{tr}|} \sum_{t \in \text{tr}} \frac{\sum_j w_j (x_{a,j}(t) - x_{t,j}(t))^2}{\sum_j w_j} + \lambda (\|U\|_F^2 + \|V\|_F^2), \quad w_j = \cos(\text{lat}_j).$$

11.3 网络架构、输入与输出

CELF 沿用阶段 ① 的 UNet(cin=4, base=32) (编码 $64 \times 96 \rightarrow 32 \times 48 \rightarrow 16 \times 24 \rightarrow 8 \times 12$, 瓶颈 128 通道, 解码最近邻上采样 + skip, 1×1 输出, 末层零初始化, 参数量 656,417)。与阶段 ① 的差异:

	阶段 ① CELF	阶段 ④ CELF
基础增益	K_s (含 inflation 的样本增益)	K_0 (无 inflation 的 raw 增益)
局地化	无 GC (网络学)	无 GC (网络学)
输出范围	$\rho = 1 + \text{out}$ (无界)	$\rho = \text{clip}(1 + \text{out}, 0, 1.5)$
损失	CLF 与 CELF 都试	仅 CELF

输入张量: 每个观测一张 $4 \times 64 \times 96$ 的图, 通道为

$$[K_0 \text{列}/\text{scale}, d(\text{观测, 格点})/8000, \cos(\text{lat}), \sigma_{\text{prior}}/\text{scale}].$$

输出张量: $1 \times 64 \times 96$ 的局地化因子图 ρ , 经 $\text{clip}(\cdot, 0, 1.5)$ 后逐元素乘到该观测的增益列上。允许 $\rho > 1$ 使 CELF 能同时承担 inflation 的放大作用。

两阶段训练 (路线 A): A1 先训练 CELF (train 1–550, val 551–600 早停, batch 形式); 冻结后计算 $\mathbf{z}_C$; A2 再在 $\mathbf{z}_C$ 上训练 U, V (同一划分)。

11.4 结果

表 11.1 评估窗 (601–1100) TAS RMSE (与 § 2.4 同口径; 5 seed)

方案	test RMSE	相对 AOEnKF_Opt
raw ensemble (无 loc/infl, $\rho = 1, U = V = 0$)	0.5805	+0.0784
CELF only (A1)	0.5261	+0.0240
CELF + PQ ($r = 5, \lambda = 10^{-3}$, 事前默认)	0.4976	−0.0045
CELF + PQ ($r = 20, \lambda = 0$, val 选中)	0.4759	−0.0262
AOEnKF_Opt (GC 7500 + inflation 1.5)	0.5021	基线
GC + PQ (阶段 ③, 1–550)	0.4724	−0.0297

- **G1 (不发散门) 通过:** CELF 单独 0.5261, 远低于门限 $1.5 \times 0.5021 = 0.7532$, 训练稳定;
- **G2 通过:** CELF+PQ 达到 **0.4759 < 0.5021**, 即在**无 GC、无 inflation** 下超越了调参最优的 GC+inflation;
- 但仍略逊于 GC+PQ (0.4724): 学习式替代可行, 性价比不及直接用 GC。




图 20 左: 各方案的评估窗 TAS RMSE 柱状对比 (灰 =raw、紫 =CELF 单独、蓝 =CELF+PQ 默认配置、绿 =CELF+PQ 最优、橙 =AOEnKF_Opt、红 =GC+PQ), 黑虚线为必须超越的 AOEnKF_Opt (0.5021)。右: PQ 秩扫描 (绿 $\lambda = 0$ 、蓝 $\lambda = 10^{-3}$, 5 seed 均值)。解读: CELF 把 raw 从 0.5805 降到 0.5261; 再叠加 PQ 降到 0.4759, 越过 AOEnKF_Opt 虚线; 秩在 $r = 20$ 附近最优, $\lambda = 10^{-3}$ 因压制过强而略差。

11.5 机制：为什么“无 GC 时 PQ 反而更有效”

直觉上，“去掉 GC 后 PQ 应更没用”，但结果相反（CELf 上 PQ 带来 0.050 改善，而 GC 上只有 0.030）。原因是两类误差的秩结构不同：




图 21 CELf 分析误差 $e_C = x_a^C - x_t$ 的加权 SVD 累积能量随秩的变化（蓝=train、橙=val、红=test）。解读：test 误差高度低秩——秩 1 即占约 55%、top-20 占 91.4%、top-50 占 95.4%；因此一个固定的低秩子空间就能去掉大部分误差，PQ 自然有效。相反，GC 之后的残差是高秩的跨模式误差，PQ 只能改善约 6%。




图 22 逐时 TAS RMSE：灰=raw、紫=CELf、绿=CELf+PQ ($r=20$)、橙=AOEnKF_Opt、红=GC+PQ；阴影为 val (551-600) 与 test (601-1100)。解读：在训练段 (1-550)，CELf+PQ 与 GC+PQ 都很低；进入 test 段后所有曲线上升，CELf+PQ (绿) 与 GC+PQ (红) 接近，且都低于 AOEnKF_Opt (橙) 与 raw (灰)。这直观显

示：无 GC/inflation 的 CELF+PQ 在整个盲测窗内稳定优于 AOEnKF_Opt。

结构解释：raw ensemble 的分析误差由有限集合的**大尺度采样噪声**主导（低秩），CELF 把它压掉一部分但留下同样低秩的残余；PQ 正好移除这部分。GC 的不可替代性在于它能压制**高秩、随距离**的伪相关，而这部分误差一旦被 GC 去掉，剩下的高秩跨模式误差就不是低秩 PQ 能处理的。因此：

$$\text{raw/CELF 误差} = \underbrace{\text{低秩大尺度}}_{\text{PQ 可去}} + \underbrace{\text{高秩远距噪声}}_{\text{只有 GC 能压}}.$$

11.6 泄漏防护与一处被修正的实现错误

环节	使用真值	说明
CELF 输入/特征	无	仅先验 X, H 与观测 y, R
CELF 损失/早停	仅 train 1-550 / val 551-600	test 不参与
z_C 计算	无	冻结 CELF + 先验 + 观测
PQ 损失/早停	仅 train 1-550 / val 551-600	见下
超参数	事前固定 + val 选择	未用 test 选参

修正记录（诚实性说明）：train_pq_on_zC.py 的初版误将 PQ 损失写成对全部 1100 步（含 test）求平均，导致 test RMSE 虚假降到 0.14（等于在测试集上拟合）。该错误已修正为只在训练窗求损失并重跑，§ 11.4 表中为修正后的结果。经核查，阶段 ③ 所用的 validate_t0.py、min_window*.py、z0_new_scheme.py 的损失均为 $xa[tr]-XT[tr]$ （仅训练窗），不受此错误影响，其历史结论有效。

11.7 小结

1. CELF 可以替代 GC + inflation：单独把 raw 从 0.5805 降到 0.5261（接近 AOEnKF_Opt）；
2. CELF + PQ 可以超越 AOEnKF_Opt：0.4759 < 0.5021 (val 选中 $r = 20, \lambda = 0$)，达成“无 GC/无 inflation 下优于调参最优 GC+inflation”；
3. 但不及 GC + PQ (0.4724)：说明 GC 所提供的高秩远距压制，用“学习式 CELF”替代的性价比更低；
4. 结构结论：raw/CELF 的分析误差是**低秩大尺度**结构，GC 之后的残差是**高秩跨模式**结构——这统一解释了阶段 ③ 与阶段 ④ 的现象。

产物：REPORT7.md、results/figs/F26_new_scheme_celf_pq.png、F27_celf_error_spectrum.png、F28_new_scheme_timeseries.png、results/zC_pq.npz|json、results/loc_celf_raw.pt；缓存 pairs_raw/、raw_ensemble_cache.npz、matrix_cache_serial_zC.npz。