

Contents

loc_learning 全弧线结果汇总（古气候 DA 学习型局地化 / 低秩状态算子 / 真值轮换 / 四候选门控） **1**

0. 摘要 1

1. 背景与统一设置 1

2. 阶段 ①：论文式 CNN 局地化迁移（Wang et al. 2023 的 CLF/CELF） 2

3. 阶段 ②：串行一致的学习型局地化（GC 残差） 2

4. 阶段 ③：低秩状态空间算子（早期主线最优） 3

5. 阶段 ④：CELF 取代 GC+inflation + PQ（无 GC / 无 inflation） 6

6. 支线：xb 算子路线（已放弃） 7

7. 真值模型轮换（同划分，池 = 其余 3 模式） 8

8. 先验诊断（为什么不同真值差异巨大） 10

9. 无纬度加权重跑（仅选择去加权） 13

10. 四候选逐时选择（观测残差门控）——TRACE 发散的修复 14

11. 总结论 15

12. 产物索引 15

13. 局限与下一步建议 16

loc_learning 全弧线结果汇总（古气候 DA 学习型局地化 / 低秩状态算子 / 真值轮换 / 四候选门控）

日期：2026-09-13 范围：online_ml/loc_learning/ 主线的全部阶段与实验（阶段 ①→④、xb 算子支线、真值模型轮换、先验诊断、无纬度加权重跑、四候选逐时选择）。**统一评价口径**：TAS (n=6144)、cos-lat 加权 RMSE；默认划分 **train 1-550 / val 551-600 / test 601-1100**（盲测），除非特别注明。**基线**：canonical AOEnKF_Opt（类比集合 K=100 ±250 窗、GC 局地化 7500 km、inflation 1.5）→ 全窗 **0.3658** / 评估窗 **0.5021**（Python 复刻与 MATLAB 逐位一致，差 8e-8）。

0. 摘要

方案	test 601-1100 TAS RMSE	说明
raw（无 loc/inflation）	0.577-0.581	起点
AOEnKF_Opt 基线（GC+infl）	0.5021	必须超越的调参最优
阶段 ③ GC+PQ（低秩状态算子）	0.4724	早期主线最优
阶段 ④ CELF+PQ（无 GC/无 inflation）	0.4759	学习式替代
四候选门控（选择）	0.4601 (MPI) / 0.5018 (TRACE)	本报告新增
Loc8000+UV（MPI，固定候选）	0.4546	当前最好
truth=TRACE（旧）	0.613-0.619	曾失效（raw 0.519-0.564）
truth=HAD_g	0.243	边际（raw 0.246）

核心结论：1. 真正带来稳定增益的是在增量 **z** 上学习低秩状态空间算子（阶段 ③，-6%）；局地化本身不是瓶颈（headroom <0.3%）。2. CELF+UV 的收益取决于真值相对先验池的“可达性/headroom”——MPI 有效、TRACE 失效、HAD_g 边际。3. TRACE 的发散已由“四候选逐时选择（观测残差门控）”修复：0.6133 → **0.5018**（满足不劣于 raw/OEnKF 基线）；同时 MPI 被推到 **0.4546**（Loc8000+UV）。

1. 背景与统一设置

- **状态**：TAS 展平 n=6144（经度最快）；**集合**：类比选择 K=100（时间窗 ±250）。
- **观测**：gwb 伪代理（1276 个位点，每时刻 388-720 个有效），观测误差方差 R。
- **模式**：trace / had_g / had_h (+ mpi)，各带状态 states_*.npy、代理空间值 Hx_*.mat、伪代理观测 pseudo_proxies_*.nc。

- 分析: $\mathbf{x}_a = \mathbf{x}_b + \mathbf{K} \mathbf{d}$; 无局地化/无 inflation 时 batch 与串行等价 (已验证逐位一致)。
- 记号: $\mathbf{x}_b$ 先验均值、 $\mathbf{z}=\mathbf{x}_a-\mathbf{x}_b$ 增量、 $\mathbf{z}_3$ canonical 增量、 $\mathbf{z}_C$ CELF 增量; $\mathbf{PQ}/\mathbf{UV}$ 即低秩算子 $\mathbf{I}+\mathbf{UV}^T$; Loc8000 指 GC 局地化 8000 km。

2. 阶段①：论文式 CNN 局地化迁移 (Wang et al. 2023 的 CLF/CELF)

方法: 逐观测 2D U-Net (4 通道: 增益列 / 距离场 / coslat / 先验离散度), 输出局地化因子 ρ ; batch 应用 $\mathbf{x}_a = \mathbf{x}_f + (\rho^* \mathbf{K}_s) \mathbf{d}$; CLF 损失 $\|\rho^* \mathbf{K}_s - \mathbf{K}_l\|_F^2$ 、CELF 损失 $\sum w(\mathbf{x}_a - \mathbf{x}_t)^2 / \sum w$; 训练 $t \in [1, 600]$ 、测试 601–1100 (因果)。

结果 (全窗 / 评估窗)

方案	全窗	评估窗
batch 无局地化	0.4231	0.5883
batch GC	0.3854	0.5403
batch CLF	0.3866	0.5518
batch CELF	0.3725	0.5385
canonical 串行 AOEnKF	0.3658	0.5021

结论: CELF 在 batch 框架下略优于 GC, 但**串行部署不稳定** (曾发散, clip[0,1.2] 后 CLF 0.5204 / CELF 0.5355), **未超越 canonical**。引擎已验证 (Python TAS-only OSEE 与 MATLAB 逐位一致)。




Figure 1: 阶段① 对比

3. 阶段②：串行一致的学习型局地化 (GC 残差)

方法: 可微串行 EnSRF 端到端训练 $\rho_{ij} = \text{clip}(\rho_{GC_{ij}} \cdot \exp(\tanh g_{\theta}(\phi_{ij})), 0, 2)$, 特征含位移/纬度/离散度/增益幅度; 损失 CELF + 0.1·CLF + 正则; 起点 $\delta=0$ 精确等于 GC。

结果: 学到 $\approx 1.08 \times \text{GC}$ (方向/纬度依赖几乎为零, 退化为距离函数); 全窗 0.3657 / 评估窗 0.5023 $\approx$ 基线。

Oracle 扫描: GC 半径 $\times$ 幅值网格最优仅 +0.16%~+0.28% $\rightarrow$ 局地化 headroom <0.3%。

结论: 局地化不是瓶颈; 乘性残差继承 GC 支撑域, 学不出 GC 之外的结构。

4. 阶段③：低秩状态空间算子（早期主线最优）

方法


$z3 = x_{a_serial} - x_f$ # canonical AOEnKF 增量 (GC+infl 之后)
 $x_a = x_f + z3 + U (V^T z3)$, $\rho = I + U V^T$, $U, V \in \mathbb{R}^{n \times r}$
损失 = CELF + $\lambda(||U||^2 + ||V||^2)$
训练 1-550 / 早停 551-600 / 盲测 601-1100

主结果


验证	基线	+ 低秩算子	改善
Split A test 601-1100	0.5021	0.4724 $\pm$ 0.0001 (5 种子)	-5.9%
Split B test 1-550	0.2510	0.2442	-2.7%
无泄漏全窗 (1-550 $\cup$ 601-1100)	0.3706	0.3441 (r_{20}, λ_0) / 0.3529 (r_5, λ_{1e-3})	-7.2% / -4.8%

机制：修正量 **99.9% 来自非对角**（跨格点混合）；秩-5 即可， $r=20$ 更优但易在测试集过拟合（选择泄漏，需早停）；对照——全局标量缩放 0.5030、逐格点对角 0.5214，**都不如低秩**（证明非“膨胀/收缩”假象）。


近邻性（最小训练窗）：以“离测试窗最近”为准，最近 100-125 步最好（test **0.4493**，比用满 1-550 的 0.4724 还好）——该修正**是非平稳/近邻主导**的。





Summary RMSE (relative to AOEnKF)







Scalar vs diagonal vs low-rank correction





Parameter sensitivity (test RMSE); white = better, red = worse



(另有 F3 误差地图、F4 Taylor、F5 纬向误差、F8 训练曲线、F9 M_t 与划分、F13 快照、F14 能量比、F15 代理位

点、F16 真值/先验、F17 流程、F18 改善/变差、F19 Split B 空间图、F20–F22 窗口实验。)

5. 阶段④： CELF 取代 GC+inflation + PQ (无 GC / 无 inflation)

方法


```
K0 = C_xh (C_hh + R)^{-1} # raw 增益 (无 loc/无 infl)
rho = clip(1 + UNet(K0列, 距离, coslat, spread), 0, 1.5) # CELF 兼任 inflation
xa_C = xf + (rho * K0) d ; z_C = xa_C - xf
xa = xf + z_C + U(V^T z_C) # PQ (同上)
```



结果 (test 601–1100)

方案	test
raw z0 (无 loc/infl)	0.5805
CELF only	0.5261
CELF+PQ (r5,λ1e-3, 事前默认)	0.4976
CELF+PQ (r20,λ0, val 选中)	0.4759
AOEnKF_Opt (必须超越)	0.5021

机制：CELF 误差在 test 上高度低秩 (top-5 83.1%、top-20 91.4%)，故低秩 PQ 能去掉大部分；而 GC 之后的残差是高秩跨模式误差，PQ 只改善 ~6%——解释了为何“修增量”有效而“修先验”无效。

诚实记录：本阶段一度因 PQ 损失误用全部 1100 步 (含 test) 得到虚假的 0.14，已修正为仅在 train 窗求损失后复跑，上表为修正后结果。





6. 支线: xb 算子路线 (已放弃)

想法: 把算子放到先验均值 $\mathbf{x}_b$ 上 ($\mathbf{x}_a = \mathbf{x}_{a_raw} + \dots \mathbf{U}(\mathbf{V}^T \mathbf{x}_b)$), 并做了 (a) 不自洽、(c) 自洽 (重算新息) 两版; 另试动态 (CELLF 式) 与与增量算子叠加。

结果 (test 601-1100)

方案	test
P1-a 静态不自洽	0.5556

方案	test
P1-c 静态自治	0.5419
P2 动态网络	0.6536
P3 增量 +xb 叠加	0.5403 (r5, $\lambda 1e-3$) / 0.7963 (r20, $\lambda 0$)
P0' 诊断	e_C 从 xb 预测 0.807, 从 zC 预测 0.486

结论：有效信息在增量 z (随观测/集合自适应) 里，不在先验 xb 里；以 xb 为输入的修正不可迁移（先验误差强非平稳：train 0.296 $\rightarrow$ test 0.657）。旁产：重建了精确的线性观测算子 H (bilinear + 逐代理局部最小二乘)， $H_{refined@state} = Hx$, RMSE $4.5e-7$, 可复用。




Figure 2: F29 xb 算子

7. 真值模型轮换（同划分，池 = 其余 3 模式）

7.1 truth=TRACE（池 had_g/had_h/mpi）——失效

方案	test 601-1100
AOEnKF-raw	0.5640
OEnKF-raw	0.5187
CELF only	0.6204
CELF+UV	0.6188

CELF 在 1-550 压到 0.21, 但 test 退化到 0.62 (跨窗非平稳); raw 基线不依赖训练窗反而更稳。

7.2 truth=HAD_g（池 trace/had_h/mpi）——边际

方案	test 601-1100
AOEnKF-raw	0.2462

方案	test 601-1100
OEnKF-raw	0.2833
CELF only	0.2401
CELF+UV	0.2426

had_g 与池距离近 → raw 已很低，学习增益空间小 (-0.006，UV 反而略差)。

7.3 窗口实验 (truth=TRACE, train 300-699 / val 700-799 / test 1-299 ∪ 800-1100) ——时段分裂

测试段	OEnKF-raw	AOEnKF-raw	CELF+UV
1-299 (训练前)	0.254	0.259	0.217
800-1100 (验证后)	0.655	0.731	0.815
union	0.455	0.496	0.517



→ 早段有效、晚段失效；逐时曲线显示晚段 (≈850 之后 trace 偏离池子) 误差被放大。

7.4 伪真值包络 + MPI 1-200 加权组合——失败

对 $m \in \{\text{trace}, \text{had_g}, \text{had_h}\}$ 轮流以 m 为假定真值 (池 = 其余 2 模式、全时段训练)，再用 MPI 1-200 学单纯形权重：601-1100 组合 **0.531** (等权 0.531、加权 0.532)，远劣于 AOEnKF_Opt 0.502、GC+PQ 0.472。

CELF+UV works for truth=MPI (0.476 < 0.581) but FAILS for truth=TRACE (0.619 > 0.519)






8. 先验诊断（为什么不同真值差异巨大）


8.1 先验组成（AOEnKF 的 K=100 来自哪个池模式，全段均值）

真值	池	组成
MPI	trace/had_g/had_h	trace 58.7% / had_g 21.0% / had_h 20.3%
TRACE	had_g/had_h/mpi	had_g 38.1% / had_h 42.1% / mpi 19.8%
HAD_g	trace/had_h/mpi	had_h 82.1%
HAD_h	trace/had_g/mpi	had_g 82.1%

had_g 与 had_h 几乎可互换（代理空间距离 0.343，其他对 0.71–0.78）→ 用其一作真值时另一个占 82%，等于真值以“兄弟模式”形式泄漏；必须把它移出先验池。



Dominant source model of the AOEnKF analog ensemble (truth truth; pool = other 3)



8.2 不对称机制


AOEnKF 选择是最近邻（约 1500 候选取距离最小 100），由距离分布下尾决定：truth=MPI 时 trace 每个分位略优（p0.5 0.823 vs 0.829）→ 占 59%（单点最优 83%），尽管其平均距离最差（1.389 vs 1.164）——纯下尾效应。truth=TRACE 时 had 对下尾略优且候选翻倍 → 合计 80%。


8.3 先验 RMSE（AOEnKF vs OEnKF，纯折线）

真值	状态空间 AOEnKF / OEnKF	观测空间 AOEnKF / OEnKF
MPI	0.4617 / 0.5010	1.1114 / 1.1716
TRACE	0.4606 / 0.4701	1.3173 / 1.4311
HAD_g	0.2586 / 0.4211	0.6063 / 0.8962
HAD_h	0.2538 / 0.4268	0.6313 / 0.9124

AOEnKF 先验始终优于 OEnKF；had_g/had_h 下优势尤其大（选中兄弟模式）。所有先验在晚段退化，TRACE 最剧。

Prior (ensemble mean) RMSE vs truth — state space





8.4 analog 代码核查

select_analog 无 bug (按加权距离取最近 K)。“OEnKF 偶尔优于 AOEnKF” 是最近邻逐成员选择 $\neq$ 集合均值最优的尾部效应：交叉极少 (mpi 49/1100、trace 67/1100)、幅度多为平局级、几乎全集中在晚段 (≥ 800)。

9. 无纬度加权重跑 (仅选择去加权)

真值	选择	AOEnKF-raw	OEnKF-raw	CELF only	CELF+UV
MPI	加权	0.5805	0.5751	0.5261	0.4759
MPI	无加权	0.5771	0.5751	0.5247	0.4737
TRACE	加权	0.5640	0.5187	0.6204	0.6188
TRACE	无加权	0.5644	0.5187	0.6197	0.6133

去加权仅边际变化 (≤ 0.006)，定性不变；故纬度加权既非 TRACE 失败原因，也非 OEnKF 偶尔更优的原因。




Figure 3: F37 加权 vs 无加权

10. 四候选逐时选择（观测残差门控）——TRACE 发散的修复

10.1 设置

每时刻并行 4 个候选（共享同一先验集合：无纬度加权类比选择，池=其余 3 模式）：

- 1 raw : $x_a = x_f + K_0 d$ (无 loc / 无 inflation)
- 2 CELF+UV : $x_a = x_f + z_C + U_C(V_C^T z_C)$ (阶段④)
- 3 Loc8000 : $x_a = x_f + z_{loc}$, z_{loc} = 串行 EnSRF(GC 8000, infl=1.0)
- 4 Loc8000+UV : $x_a = x_f + z_{loc} + U_L(V_L^T z_{loc})$ (UV_loc 单独在该 loc 增量上训练)

逐时选择：观测空间残差最小者（cos-lat 加权）；另给 R 归一化 chi2 版对照

划分 1-550 / 551-600 / 601-1100；评估 TAS cos-lat 加权 RMSE

10.2 结果 (test 601-1100)

	raw	CELF+UV	Loc8000	Loc8000+UV	选择 (obs-res)	选择 (chi2)	oracle(诊断)
MPI	0.5771	0.4737	0.5097	0.4546	0.4601	0.4991	0.4488
TRACE	0.5644	0.6133	0.5131	0.6220	0.5018	0.5122	0.4916


被选比例 (test, obs-res): MPI raw 0 / celf 19.2% / loc 25.0% / loc_uv 55.8%; TRACE raw 0 / celf 6.2% / loc 61.0% / loc_uv 32.8%。

10.3 结论

1. 加入 Loc 候选是关键增益：
 - MPI: **Loc8000+UV = 0.4546**, 创下新最好（超过阶段 ③ 0.4724、CELF+UV 0.4737）；
 - TRACE: **Loc8000 = 0.5131**, 远好于 raw 0.5644 / CELF+UV 0.6133。
2. 逐时选择 (obs-res):
 - TRACE 0.5018: 优于全部固定候选、满足 “不劣于 raw/OEnKF 基线” 的目标，逼近 oracle 0.4916——晚段自动避开 CELF+UV / UV_loc 的发散；
 - MPI 0.4601: 优于此前最好 (0.4724)，但略逊于固定最优 loc_uv 0.4546（选择器对 MPI 并非最优）。
3. chi2 (R 归一化) 判据反而更差 (0.4991 / 0.5122) ——本数据上朴素 cos-lat 加权残差更可靠。
4. oracle 仅诊断：用真值事后逐时选最优，不可实现；且口径敏感——“逐时 min RMSE” 口径 MPI 0.4488，而 “总体 RMSE (先平方再开方)” 口径 MPI 0.4873 / TRACE 0.5514。

Caveat: 判据与四候选共用同一 y（有轻微 “过拟合观测” 风险，MPI 选择器离 oracle 仍差 0.011）；逐时硬切换（驻留/滞回功能已预留未启用）。

4-candidate per-step selection by observation-space residual



11. 总结论

- 有效的学习对象是“分析增量 z ”，不是“增量权重（局地化）”，也不是“先验 xb ”：
 - 低秩状态算子（阶段③）稳定增益 -6% （ $0.5021 \rightarrow 0.4724$ ）；
 - 局地化 headroom $< 0.3\%$ （阶段①② 验证）；
 - xb 算子不可迁移（支线）。
- CELF+UV 的收益取决于真值相对先验池的“可达性/headroom”：MPI 有效、TRACE 失效（真值后段离群）、HAD_g 边际（先验已很近）。
- TRACE 发散可由“四候选逐时选择（观测残差门控）”修复： $0.6133 \rightarrow 0.5018$ ；同一框架还把 MPI 推到新最好 0.4546 （Loc8000+UV）。
- 真值模型轮换的陷阱：had_g/had_h 近乎重复 $\rightarrow$ 用作真值时必须把兄弟模式移出先验池；否则“真值泄漏”。
- 方法论教训：跨窗强非平稳（不可迁移）；禁用测试集早停/选参；OEnKF 随机不可逐位复现；选择类判据需注意“与候选共用观测”的过拟合风险。
- 当前最好：Loc8000+UV 0.4546 （MPI，四候选框架）、四候选选择 0.4601 （MPI）/ 0.5018 （TRACE）；基线 AOEnKF_Opt 0.5021 。

12. 产物索引

代码(节选): osee_tas.py, build_pairs*.py, train_loc.py, serial_torch.py, train_serial.py, build_matrix_cache.py, build_serial_analysis.py, train_matrix_rho.py, train_celf_raw.py, eval_celf_raw.py, train_pq_on_zC.py, build_H.py/build_H2.py, train_xb_operator.py, build_pairs_pseudo.py, train_uv_generic.py, prior_composition.py, prior_rmse.py, eval_unw.py, build_loc_candidate.py, eval_select.py, make_fig_select4.py。

报告: INTERNAL_REPORT.md、LEARNED_LOCALIZATION_REPORT.md(+pdf)、CNN_LOCALIZATION_MIGRATION.md、REPORT3-REPORT16.md、POPRIME.md、prior_asymmetry.md。

关键缓存/模型: pairs*/matrix_cache*.npz, loc_celf*.pt, uv*.npz, H_refined.npz, raw*.json, prior_composition.json, unw_summary.json, loc8000*.npz, zloc*.npz, uvloc*.npz, select4.json|npz。

图: F1-F39（见 results/figs/）。

13. 局限与下一步建议

- **局限：**伪代理观测噪声大且站点不规则；模型池仅 3+1 个、且 had_g/had_h 近乎重复；评估窗（6-11 ka 深冰消）与训练窗非平稳；OEnKF 单种子；四候选选择判据与候选共用观测。
- **建议：**
 1. 以“可达性/headroom”为准则筛选可用真值场景（先做先验诊断再训练）；
 2. 提升选择器：改进判据（ χ^2 结合集合离散度/HPH^T+R）、加入驻留/滞回与置信度，目标逼近 oracle；或按工况自适应候选集合；
 3. 在更丰富的模式池上验证阶段 ③/Loc+UV 的普适性；真值轮换必须“真值不入池 + 兄弟模式排除 + 独立验证集”。